

NLTK

July 5, 2026

1 Práctica 3: Procesamiento del lenguaje natural

2 Inteligencia Artificial

3 Grado en Ingeniería Informática - Ingeniería del Software

4 Universidad de Sevilla

NLTK (*Natural Language Toolkit*) es una biblioteca de Python para trabajar con datos del lenguaje humano. Proporciona interfaces fáciles de usar para más de 50 corpus y recursos léxicos, junto con un conjunto de herramientas de procesamiento de texto para clasificación, tokenización, derivación, etiquetado, análisis y razonamiento semántico. Esta práctica presenta una introducción a esa biblioteca, mostrando cómo construir un filtro de correo electrónico no deseado y un sistema de texto predictivo.

En esta práctica también se hará uso de la biblioteca scikit-learn.

En primer lugar establecemos la semilla aleatoria inicial, para que el cuaderno sea reproducible.

```
[2]: import numpy as np
     np.random.seed(357823)
```

4.1 Filtro de correo electrónico no deseado

En la comunicación por correo electrónico se emplea el término *spam* para designar a aquellos mensajes enviados de forma masiva y que no han sido solicitados por sus destinatarios. Los gestores de correo electrónico suelen incorporar la posibilidad de crear filtros de mensajes no deseados que permitan identificar estos de forma automática y actuar en consecuencia (usualmente moviéndolos de la bandeja de entrada a una carpeta específica).

En esta primera parte de la práctica se va a construir un filtro de correo electrónico que, aplicando técnicas de aprendizaje automático, identifique lo mejor posible los mensajes no deseados. En concreto, se van a considerar los siguientes modelos predictivos:

- Modelo naive Bayes multinomial, usando el modelo de bolsa de palabras como modelo de lenguaje. Se probarán distintos valores del parámetro de suavizado.
- Modelo k NN, usando el modelo tf-idf como modelo de lenguaje. Se probarán distintos valores del número de vecinos.

Para entrenar los modelos y evaluar su rendimiento se usará [Enron-Spam](#), que es un conjunto público de mensajes (en inglés) de correo electrónico, ya preclasificados en mensajes legítimos y no deseados. Este conjunto se encuentra en la carpeta `Filtro antispam/Enron-Spam/`, dividido en las subcarpetas `train/` (subconjunto de entrenamiento) y `test/` (subconjunto de prueba). En cada una de estas subcarpetas, los mensajes se encuentran organizados, a su vez, en subcarpetas `legítimo` y `no_deseado`.

Los mensajes se proporcionan en bruto, incluyendo las cabeceras. Para su lectura usaremos el paquete `email` de la biblioteca estándar de Python. Por ejemplo, el contenido del mensaje no deseado 5 del subconjunto de entrenamiento se puede obtener con el siguiente código.

```
[2]: from email import parser
     from email import policy
```

```
[11]: analizador_mensaje = parser.Parser(policy=policy.default)
     with open('Filtro antispam/Enron-Spam/train/no_deseado/5') as fichero_mensaje:
         mensaje = analizador_mensaje.parse(fichero_mensaje)
         contenido_mensaje_5 = mensaje.get_content()
     contenido_mensaje_5
```

```
[11]: "Hi, \nI have a special offer available for you at our casino.\n\n$20 to try our
internet casino, no deposit is necessary!\nAt the casino software's cashier
enter bonus code: FR93P\n\n$200 bonus on your first deposit!\nAt the casino
software's cashier enter bonus code: FMJKU\n\nAllow us to show you our quality
operation, fast payouts,\ngenerous bonuses, and super friendly around-the-
clock\ncustomer support.\n\nClick here: http://bigbonus-casino.net \n\nBest
regards,\nJamie Zawinsky\n\n\nNo thanks: http://bigbonus-casino.com/u/\n\n"
```

Antes de poder entrenar un modelo de aprendizaje automático capaz de discriminar los mensajes legítimos de los no deseados, es necesario vectorizar el contenido de los mensajes. Es decir, representar esos contenidos mediante vectores numéricos.

En esta práctica, la vectorización del contenido de los mensajes se va a llevar a cabo haciendo uso de un vocabulario fijo de términos que aparecen habitualmente en correos electrónicos no deseados. Ese vocabulario se ha extraído de [spam_words_api_lists](#) y se encuentra en el fichero `Filtro antispam/términos_spam.txt`.

```
[ ]: with open('Filtro antispam/términos_spam.txt', 'r') as f:
     términos_spam = f.read()
     términos_spam = términos_spam.split(sep='\n')

     print(f"términos: {len(términos_spam)}")
```

```
términos: 494
```

El paquete `pprint` de la biblioteca estándar de Python facilita mostrar el vocabulario de una manera compacta.

```
[17]: from pprint import pprint
```

```
[47]: pprint(términos_spam, compact=True)
print(f"términos: {len(términos_spam)}")
```

```
['#1', '$$$', '$earn extra cash', '$save big money', '$save', '100% free',
'100% satisfied', '100%', '4u', '50% off', 'accept credit cards', 'acceptance',
'access', 'accordingly', 'act now!', 'act now', 'action', 'ad',
'additional income', 'additional', 'addresses on cd', 'affordable',
'all natural', 'all new', 'amazed', 'amazing stuff', 'amazing', 'americans',
'apply now', 'apply online', 'as seen on', 'auto email removal',
'avoid bankruptcy', 'avoid', 'bargain', 'be amazed', 'be your own boss',
'being a member', 'beneficiary', 'best price', 'beverage', 'big bucks cash',
'big bucks', 'bill 1618', 'billing address', 'billing', 'billion dollars',
'billion', 'bonus', 'boss', 'brand new pager', 'bulk email', 'buy direct',
'buy', 'buying judgments', 'cable converter', 'call free', 'call now', 'call',
'calling creditors', "can't live without", 'cancel at any time', 'cancel',
'cannot be combined with any other offer', 'can't live without',
'cards accepted', 'cash bonus', 'cash', 'cashcashcash', 'casino', 'celebrity',
'cell phone cancer scam', 'cents on the dollar', 'certified',
'certifiedchance', 'chance', 'cheap', 'check or money order', 'check',
'checkclaims', 'claims not to be selling anything',
'claims to be in accordance with some spam law', 'claims to be legal',
'claims', 'clearance', 'click below', 'click here', 'click to remove', 'click',
'collect child support', 'collect', 'compare rates', 'compare',
'compete for your business', 'confidentially on all orders', 'congratulations',
'consolidate debt and credit', 'consolidate your debt', 'copy accurately',
'copy dvd', 'copy dvds', 'cost', 'costs', 'credit bureaus discount',
'credit bureaus', 'credit card offers', 'credit', 'cures baldness', 'cures',
'deal', 'dear', 'debt', 'diagnostics', 'dig up dirt on friends',
'direct email', 'direct marketing', 'discount', 'do it today', "don't delete",
"don't hesitate", 'don't delete', 'don't hesitate', 'dormant',
'double your cash', 'double your income', 'double your', 'drastically reduced',
'earn $', 'earn extra cash', 'earn per week', 'earn', 'easy terms f r e e',
'easy terms', 'eliminate bad credit', 'eliminate debt', 'email harvest',
'email marketing', 'exclusive deal', 'expect to earn', 'expire',
'explode your business', 'extra cash', 'extra income', 'extra', 'f r e e',
'fantastic deal', 'fantastic', 'fast cash', 'fast viagra delivery', 'fast',
'financial freedom', 'financially independent', 'for free',
'for instant access', 'for just $', 'for only', 'for you', 'form',
'free access', 'free cell phone', 'free consultation', 'free dvd', 'free gift',
'free grant money', 'free hosting', 'free info', 'free installation',
'free instant', 'free investment', 'free leads', 'free membership',
'free money', 'free offer', 'free preview', 'free priority mail', 'free quote',
'free sample', 'free trial', 'free website', 'free', 'freedom', 'friend',
'full refund', 'get it now', 'get out of debt', 'get paid', 'get started now',
'get', 'gift certificate', 'give it away', 'giving away', 'great offer',
'great', 'guarantee', 'guaranteed', 'have you been turned down?', 'hello',
'here', 'hidden assets', 'hidden charges', 'hidden', 'home based business',
'home based', 'home employment', 'home', 'homebased business',
```

'human growth hormone', 'if only it were that easy',
'important information regarding', 'in accordance with laws',
'income from home', 'income', 'increase sales', 'increase traffic',
'increase your sales', 'incredible deal', 'info you requested',
'information you requested', 'instant', 'insurance', 'internet market',
'internet marketing', 'investment decision', 'investment', 'it's effective',
'join millions of americans', 'join millions of', 'join millions', 'junk',
'laser printer', 'leave', 'legal', 'life insurance', 'life', 'lifetime',
'limited time offer', 'limited time only', 'limited time', 'limited', 'loan',
'loans', 'long distance phone offer', 'lose weight spam', 'lose weight',
'lose weightlose weight spam', 'lose', 'lower interest rate',
'lower interest rates', 'lower monthly payment', 'lower your mortgage rate',
'lowest insurance rates', 'lowest price', 'luxury car', 'luxury',
'mail in order form', 'maintained', 'make \$', 'make money',
'marketing solutions', 'marketing', 'mass email', 'medicine', 'medium',
'meet singles', 'member stuff', 'member', 'message contains disclaimer',
'message contains', 'million dollars', 'million', 'miracle', 'mlm',
'money back', 'money making', 'money', 'month trial offer',
'more internet traffic', 'mortgage rates', 'mortgage', 'multi level marketing',
'multi-level marketing', 'name brand', 'never', 'new customers only',
'new domain extensions', 'nigerian', 'no age restrictions', 'no catch',
'no claim forms', 'no cost', 'no credit check', 'no disappointment',
'no experience', 'no fees', 'no gimmick', 'no hidden costs', 'no hidden',
'no interests', 'no inventory', 'no investment', 'no medical exams',
'no middleman', 'no obligation', 'no purchase necessary', 'no questions asked',
'no refund!', 'no refund', 'no selling', 'no strings attached',
'no-obligation', 'not intended', 'not intendednot junk', 'not spam', 'notspam',
'now only', 'now', 'obligation', 'off shore', 'offer expires', 'offer',
'offshore', 'once in lifetime', 'one hundred percent free',
'one hundred percent guaranteed', 'one time mailing', 'one time',
'online biz opportunity', 'online degree', 'online marketing',
'online pharmacy', 'only \$', 'only', 'open', 'opportunity', 'opt in',
'order now', 'order shipped by', 'order status', 'order today', 'order',
'orders shipped by', 'outstanding values', 'passwords', 'pennies a day price',
'pennies a day', 'per day', 'per week', 'performance', 'phone', 'please read',
'potential earnings', 'pre-approved', 'presently', 'price',
'print form signature', 'print out and fax', 'priority mail', 'prize',
'prizes', 'problem', 'produced and sent out', 'profits', 'promise you',
'promise', 'purchase', 'pure profit', 'pure profits', 'quote', 'rates',
'real thing', 'refinance home', 'refinance', 'refund', 'removal instructions',
'removal', 'remove', 'removes wrinkles', 'request',
'requires initial investment', 'reserves the right', 'reverses aging',
'reverses', 'risk free', 'rolex', 'round the world', 's 1618',
'safeguard notice', 'sale', 'sales', 'sample', 'satisfaction guaranteed',
'satisfaction', 'satisfied', 'save \$', 'save big money', 'save up to', 'save',
'score with babes', 'score', 'search engine listings', 'search engines',
'section 301', 'see for yourself', 'sent in compliance', 'serious cash',
'serious only', 'serious', 'shopper', 'shopping spree', 'sign up free today',

```
'social security number', 'solution', 'spam', 'special promotion',
'stainless steel', 'stock alert', 'stock disclaimer statement', 'stock pick',
'stop snoring', 'stop', 'strong buy', 'stuff on sale', 'subject to cash',
'subject to credit', 'subscribe', 'subscribethe following form', 'success',
'supplies are limited', 'supplies', 'take action now', 'take action',
'talks about hidden charges', 'talks about prizes', 'teen',
'tells you it's an ad', 'terms and conditions', 'terms', 'the best rates',
'the following form', 'they keep your money', 'they're just giving it away',
'this isn't junk', 'this isn't spam', 'this isn't a scam', 'this isn't junk',
'this isn't spam', 'this won't last', 'thousands', 'time limited', 'traffic',
'trial', 'undisclosed recipient', 'university diplomas', 'unlimited',
'unsecured credit', 'unsecured debt', 'unsolicited', 'unsubscribe', 'urgent',
'us dollars', 'vacation offers', 'vacation', 'valium', 'viagra delivery',
'viagra', 'vicodin', 'visit our website', 'wants credit card', 'warranty',
'we hate spam', 'we honor all', 'web traffic', 'weekend getaway',
'weight loss', 'weight', 'what are you waiting for?', 'what's keeping you?',
'while supplies last', 'while you sleep', 'who really wins?', 'why pay more?',
'wife', 'will not believe your eyes', 'win', 'winner', 'winning', 'won',
'work at home', 'work from home', 'xanax', 'you are a winner!',
'you have been selected', 'your income', 'you're a winner!']
términos: 494
```

Obsérvese que el vocabulario contiene términos de hasta 9 palabras, algo que habrá que tener en cuenta al construir los vectorizadores del contenido de los mensajes.

```
[19]: max(len(término.split()) for término in términos_spam)
```

```
[19]: 9
```

El primer vectorizador que vamos a construir es el modelo de bolsa de palabras, que representará el contenido de cada mensaje mediante **el vector del número de ocurrencias en el mensaje de cada término del vocabulario**. La clase `CountVectorizer` de `scikit-learn` implementa este modelo de lenguaje.

```
[20]: from sklearn.feature_extraction.text import CountVectorizer
```

Una vez creada una instancia de esta clase, sería posible, a través del método `fit`, pedirle que aprendiera el vocabulario de términos a partir de un corpus de entrenamiento. Nosotros, sin embargo, usamos un vocabulario fijo y, por tanto, hay que proporcionárselo explícitamente.

```
[21]: vectorizador = CountVectorizer(vocabulary=términos_spam)
```

Ahora basta aplicar el método `fit_transform` del vectorizador para obtener la representación como bolsa de palabras de la secuencia de contenidos de mensajes proporcionada. A la hora de mostrar esa representación, debe tenerse en cuenta que se obtiene en forma de matriz dispersa (*sparse matrix*).

Nota: aunque, como se ha comentado antes, el vocabulario es fijo, sigue siendo adecuado aplicar el método `fit`, ya que este realiza una serie de comprobaciones convenientes.

- construcción de n-gramas según `ngram_range`,
- filtrados internos del vectorizador.
- Se le pasa el texto crudo directamente.

En tu caso concreto:

`tokenizador(...)` te devuelve palabras/tokens. `analizador(...)` te devuelve las características finales que se van a contar (con tu configuración, desde 1-gramas hasta 9-gramas). Regla práctica:

- Si quieres inspeccionar cómo se parte el texto: `build_tokenizer`.
- Si quieres ver exactamente qué usa `CountVectorizer` para crear el vector: `build_analyzer`.

```
[27]: preprocesador = vectorizador.build_preprocessor()
preprocesador(contenido_mensaje_5)
```

```
[27]: "hi, \ni have a special offer available for you at our casino.\n\n$20 to try our
internet casino, no deposit is necessary!\nat the casino software's cashier
enter bonus code: fr93p\n\n$200 bonus on your first deposit!\nat the casino
software's cashier enter bonus code: fmjku\n\nallow us to show you our quality
operation, fast payouts,\ngenerous bonuses, and super friendly around-the-
clock\ncustomer support.\n\nclick here: http://bigbonus-casino.net \n\nbest
regards,\njamie zawinsky\n\n\nno thanks: http://bigbonus-casino.com/u/\n\n"
```

```
[33]: tokenizador = vectorizador.build_tokenizer()
pprint(tokenizador(preprocesador(contenido_mensaje_5)),
        compact=True)
```

```
['hi', 'have', 'special', 'offer', 'available', 'for', 'you', 'at', 'our',
'casino', '20', 'to', 'try', 'our', 'internet', 'casino', 'no', 'deposit',
'is', 'necessary', 'at', 'the', 'casino', 'software', 'cashier', 'enter',
'bonus', 'code', 'fr93p', '200', 'bonus', 'on', 'your', 'first', 'deposit',
'at', 'the', 'casino', 'software', 'cashier', 'enter', 'bonus', 'code',
'fmjku', 'allow', 'us', 'to', 'show', 'you', 'our', 'quality', 'operation',
'fast', 'payouts', 'generous', 'bonuses', 'and', 'super', 'friendly', 'around',
'the', 'clock', 'customer', 'support', 'click', 'here', 'http', 'bigbonus',
'casino', 'net', 'best', 'regards', 'jamie', 'zawinsky', 'no', 'thanks',
'http', 'bigbonus', 'casino', 'com']
```

```
[34]: analizador = vectorizador.build_analyzer()
pprint(analizador(contenido_mensaje_5),
        compact=True)
```

```
['hi', 'have', 'special', 'offer', 'available', 'for', 'you', 'at', 'our',
'casino', '20', 'to', 'try', 'our', 'internet', 'casino', 'no', 'deposit',
'is', 'necessary', 'at', 'the', 'casino', 'software', 'cashier', 'enter',
'bonus', 'code', 'fr93p', '200', 'bonus', 'on', 'your', 'first', 'deposit',
'at', 'the', 'casino', 'software', 'cashier', 'enter', 'bonus', 'code',
'fmjku', 'allow', 'us', 'to', 'show', 'you', 'our', 'quality', 'operation',
'fast', 'payouts', 'generous', 'bonuses', 'and', 'super', 'friendly', 'around',
'the', 'clock', 'customer', 'support', 'click', 'here', 'http', 'bigbonus',
```

```
'casino', 'net', 'best', 'regards', 'jamie', 'zawinsky', 'no', 'thanks',  
'http', 'bigbonus', 'casino', 'com']
```

Para nuestros propósitos, nos interesa usar un tokenizador más avanzado que el usado por defecto. En concreto, usaremos el tokenizador recomendado por NLTK, que divide cualquier texto en párrafos, frases y palabras como sigue: las líneas en blanco separan los párrafos; las frases se separan en palabras formadas bien por secuencias de caracteres alfanuméricos, bien por secuencias de caracteres no alfanuméricos ni espacios (que se descartan); los párrafos se separan en frases usando un modelo entrenado mediante aprendizaje no supervisado que se ha comprobado que funciona bien para muchos lenguajes europeos.

El tokenizador está implementado por la función `word_tokenize` del módulo `nltk.tokenize`, que usa el modelo de separación de párrafos en frases implementado en el módulo `nltk.tokenize.punkt`. En principio, la documentación recomienda entrenar este modelo con un corpus adecuado para la tarea que se pretende realizar. No obstante, NLTK proporciona modelos preentrenados para distintos idiomas, pero para poder usarlos es necesario descargar previamente sus parámetros.

```
[35]: # Los corpus, gramáticas, tokenizadores, etcétera que proporciona NLTK se
      ↪descargan y buscan en ciertas carpetas por defecto.
      # Para usar una carpeta distinta a ellas es necesario establecer la variable de
      ↪entorno NLTK_DATA, con la prevención de hacerlo
      # antes de cargar el paquete nltk
```

```
import os
os.environ['NLTK_DATA'] = '.'
```

```
[37]: from nltk import download

      download('punkt_tab')
```

```
[nltk_data] Downloading package punkt_tab to ...
[nltk_data]   Unzipping tokenizers/punkt_tab.zip.
```

```
[37]: True
```

```
[38]: from nltk.tokenize import word_tokenize
```

Basta entonces indicarle al vectorizador que use el tokenizador proporcionado por NLTK que, además, por defecto usa el modelo de separación en frases preentrenado para el idioma inglés. También nos interesa que los atributos construidos por el analizador sean desde unigramas hasta 9-gramas.

```
[39]: vectorizador = CountVectorizer(vocabulary=términos_spam,
      ↪token_pattern=None, # Anulamos el tokenizador
      ↪por defecto basado en expresiones regulares
      ↪tokenizer=word_tokenize, # Usamos el
      ↪tokenizador proporcionado por NLTK
      ↪ngram_range=(1, 9))
```

```
[40]: tokenizador = vectorizador.build_tokenizer()
      pprint(tokenizador(preprocesador(contenido_mensaje_5)),
              compact=True)
```

```
['hi', ',', 'i', 'have', 'a', 'special', 'offer', 'available', 'for', 'you',
 'at', 'our', 'casino', '.', '$', '20', 'to', 'try', 'our', 'internet',
 'casino', ',', 'no', 'deposit', 'is', 'necessary', '!', 'at', 'the', 'casino',
 'software', '"s', 'cashier', 'enter', 'bonus', 'code', ':', 'fr93p', '$',
 '200', 'bonus', 'on', 'your', 'first', 'deposit', '!', 'at', 'the', 'casino',
 'software', '"s', 'cashier', 'enter', 'bonus', 'code', ':', 'fmjku', 'allow',
 'us', 'to', 'show', 'you', 'our', 'quality', 'operation', ',', 'fast',
 'payouts', ',', 'generous', 'bonuses', ',', 'and', 'super', 'friendly',
 'around-the-clock', 'customer', 'support', '.', 'click', 'here', ':', 'http',
 ':', '//bigbonus-casino.net', 'best', 'regards', ',', 'jamie', 'zawinsky',
 'no', 'thanks', ':', 'http', ':', '//bigbonus-casino.com/u/']
```

```
[41]: analizador = vectorizador.build_analyzer()
      pprint(analizador(contenido_mensaje_5),
              compact=True)
```

```
['hi', ',', 'i', 'have', 'a', 'special', 'offer', 'available', 'for', 'you',
 'at', 'our', 'casino', '.', '$', '20', 'to', 'try', 'our', 'internet',
 'casino', ',', 'no', 'deposit', 'is', 'necessary', '!', 'at', 'the', 'casino',
 'software', '"s', 'cashier', 'enter', 'bonus', 'code', ':', 'fr93p', '$',
 '200', 'bonus', 'on', 'your', 'first', 'deposit', '!', 'at', 'the', 'casino',
 'software', '"s', 'cashier', 'enter', 'bonus', 'code', ':', 'fmjku', 'allow',
 'us', 'to', 'show', 'you', 'our', 'quality', 'operation', ',', 'fast',
 'payouts', ',', 'generous', 'bonuses', ',', 'and', 'super', 'friendly',
 'around-the-clock', 'customer', 'support', '.', 'click', 'here', ':', 'http',
 ':', '//bigbonus-casino.net', 'best', 'regards', ',', 'jamie', 'zawinsky',
 'no', 'thanks', ':', 'http', ':', '//bigbonus-casino.com/u/', 'hi', ',', 'i',
 'i have', 'have a', 'a special', 'special offer', 'offer available',
 'available for', 'for you', 'you at', 'at our', 'our casino', 'casino .',
 '. $', '$ 20', '20 to', 'to try', 'try our', 'our internet', 'internet casino',
 'casino ,', 'no', 'no deposit', 'deposit is', 'is necessary', 'necessary !',
 '! at', 'at the', 'the casino', 'casino software', 'software "s', '"s cashier',
 'cashier enter', 'enter bonus', 'bonus code', 'code :', ': fr93p', 'fr93p $',
 '$ 200', '200 bonus', 'bonus on', 'on your', 'your first', 'first deposit',
 'deposit !', '!', 'at', 'at the', 'the casino', 'casino software', 'software "s',
 '"s cashier', 'cashier enter', 'enter bonus', 'bonus code', 'code :',
 ': fmjku', 'fmjku allow', 'allow us', 'us to', 'to show', 'show you',
 'you our', 'our quality', 'quality operation', 'operation ,', 'fast',
 'fast payouts', 'payouts ,', 'generous', 'generous bonuses', 'bonuses ,',
 ', and', 'and super', 'super friendly', 'friendly around-the-clock',
 'around-the-clock customer', 'customer support', 'support .', '. click',
 'click here', 'here :', ': http', 'http :', ': //bigbonus-casino.net',
 '//bigbonus-casino.net best', 'best regards', 'regards ,', 'jamie',
 'jamie zawinsky', 'zawinsky no', 'no thanks', 'thanks :', ': http', 'http :',
```

': //bigbonus-casino.com/u/', 'hi , i', ', i have', 'i have a',
 'have a special', 'a special offer', 'special offer available',
 'offer available for', 'available for you', 'for you at', 'you at our',
 'at our casino', 'our casino .', 'casino . \$', '. \$ 20', '\$ 20 to',
 '20 to try', 'to try our', 'try our internet', 'our internet casino',
 'internet casino ,', 'casino , no', ', no deposit', 'no deposit is',
 'deposit is necessary', 'is necessary !', 'necessary ! at', '! at the',
 'at the casino', 'the casino software', 'casino software 's',
 'software 's cashier', "'s cashier enter", 'cashier enter bonus',
 'enter bonus code', 'bonus code :', 'code : fr93p', ': fr93p \$', 'fr93p \$ 200',
 '\$ 200 bonus', '200 bonus on', 'bonus on your', 'on your first',
 'your first deposit', 'first deposit !', 'deposit ! at', '! at the',
 'at the casino', 'the casino software', 'casino software 's',
 'software 's cashier', "'s cashier enter", 'cashier enter bonus',
 'enter bonus code', 'bonus code :', 'code : fmjku', ': fmjku allow',
 'fmjku allow us', 'allow us to', 'us to show', 'to show you', 'show you our',
 'you our quality', 'our quality operation', 'quality operation ,',
 'operation , fast', ', fast payouts', 'fast payouts ,', 'payouts , generous',
 ', generous bonuses', 'generous bonuses ,', 'bonuses , and', ', and super',
 'and super friendly', 'super friendly around-the-clock',
 'friendly around-the-clock customer', 'around-the-clock customer support',
 'customer support .', 'support . click', '. click here', 'click here :',
 'here : http', ': http :', 'http : //bigbonus-casino.net',
 ': //bigbonus-casino.net best', '///bigbonus-casino.net best regards',
 'best regards ,', 'regards , jamie', ', jamie zawinsky', 'jamie zawinsky no',
 'zawinsky no thanks', 'no thanks :', 'thanks : http', ': http :',
 'http : //bigbonus-casino.com/u/', 'hi , i have', ', i have a',
 'i have a special', 'have a special offer', 'a special offer available',
 'special offer available for', 'offer available for you',
 'available for you at', 'for you at our', 'you at our casino',
 'at our casino .', 'our casino . \$', 'casino . \$ 20', '. \$ 20 to',
 '\$ 20 to try', '20 to try our', 'to try our internet',
 'try our internet casino', 'our internet casino ,', 'internet casino , no',
 'casino , no deposit', ', no deposit is', 'no deposit is necessary',
 'deposit is necessary !', 'is necessary ! at', 'necessary ! at the',
 '! at the casino', 'at the casino software', 'the casino software 's',
 'casino software 's cashier', 'software 's cashier enter',
 "'s cashier enter bonus", 'cashier enter bonus code', 'enter bonus code :',
 'bonus code : fr93p', 'code : fr93p \$', ': fr93p \$ 200', 'fr93p \$ 200 bonus',
 '\$ 200 bonus on', '200 bonus on your', 'bonus on your first',
 'on your first deposit', 'your first deposit !', 'first deposit ! at',
 'deposit ! at the', '! at the casino', 'at the casino software',
 'the casino software 's', 'casino software 's cashier',
 'software 's cashier enter', "'s cashier enter bonus",
 'cashier enter bonus code', 'enter bonus code :', 'bonus code : fmjku',
 'code : fmjku allow', ': fmjku allow us', 'fmjku allow us to',
 'allow us to show', 'us to show you', 'to show you our',
 'show you our quality', 'you our quality operation', 'our quality operation ,',

'quality operation , fast', 'operation , fast payouts', ', fast payouts ,',
 'fast payouts , generous', 'payouts , generous bonuses',
 ', generous bonuses ,', 'generous bonuses , and', 'bonuses , and super',
 ', and super friendly', 'and super friendly around-the-clock',
 'super friendly around-the-clock customer',
 'friendly around-the-clock customer support',
 'around-the-clock customer support .', 'customer support . click',
 'support . click here', '. click here :', 'click here : http', 'here : http :',
 ': http : //bigbonus-casino.net', 'http : //bigbonus-casino.net best',
 ': //bigbonus-casino.net best regards', '//bigbonus-casino.net best regards ,',
 'best regards , jamie', 'regards , jamie zawinsky', ', jamie zawinsky no',
 'jamie zawinsky no thanks', 'zawinsky no thanks :', 'no thanks : http',
 'thanks : http :', ': http : //bigbonus-casino.com/u/', 'hi , i have a',
 ', i have a special', 'i have a special offer',
 'have a special offer available', 'a special offer available for',
 'special offer available for you', 'offer available for you at',
 'available for you at our', 'for you at our casino', 'you at our casino .',
 'at our casino . \$', 'our casino . \$ 20', 'casino . \$ 20 to', '. \$ 20 to try',
 '\$ 20 to try our', '20 to try our internet', 'to try our internet casino',
 'try our internet casino ,', 'our internet casino , no',
 'internet casino , no deposit', 'casino , no deposit is',
 ', no deposit is necessary', 'no deposit is necessary !',
 'deposit is necessary ! at', 'is necessary ! at the',
 'necessary ! at the casino', '! at the casino software',
 'at the casino software 's', 'the casino software 's cashier',
 'casino software 's cashier enter', 'software 's cashier enter bonus',
 "'s cashier enter bonus code", 'cashier enter bonus code :',
 'enter bonus code : fr93p', 'bonus code : fr93p \$', 'code : fr93p \$ 200',
 ': fr93p \$ 200 bonus', 'fr93p \$ 200 bonus on', '\$ 200 bonus on your',
 '200 bonus on your first', 'bonus on your first deposit',
 'on your first deposit !', 'your first deposit ! at', 'first deposit ! at the',
 'deposit ! at the casino', '! at the casino software',
 'at the casino software 's', 'the casino software 's cashier',
 'casino software 's cashier enter', 'software 's cashier enter bonus',
 "'s cashier enter bonus code", 'cashier enter bonus code :',
 'enter bonus code : fmjku', 'bonus code : fmjku allow',
 'code : fmjku allow us', ': fmjku allow us to', 'fmjku allow us to show',
 'allow us to show you', 'us to show you our', 'to show you our quality',
 'show you our quality operation', 'you our quality operation ,',
 'our quality operation , fast', 'quality operation , fast payouts',
 'operation , fast payouts ,', ', fast payouts , generous',
 'fast payouts , generous bonuses', 'payouts , generous bonuses ,',
 ', generous bonuses , and', 'generous bonuses , and super',
 'bonuses , and super friendly', ', and super friendly around-the-clock',
 'and super friendly around-the-clock customer',
 'super friendly around-the-clock customer support',
 'friendly around-the-clock customer support .',
 'around-the-clock customer support . click', 'customer support . click here',

'support . click here :', '. click here : http', 'click here : http :',
 'here : http : //bigbonus-casino.net', ': http : //bigbonus-casino.net best',
 'http : //bigbonus-casino.net best regards',
 ': //bigbonus-casino.net best regards ,',
 '//bigbonus-casino.net best regards , jamie', 'best regards , jamie zawinsky',
 'regards , jamie zawinsky no', ', jamie zawinsky no thanks',
 'jamie zawinsky no thanks :', 'zawinsky no thanks : http',
 'no thanks : http :', 'thanks : http : //bigbonus-casino.com/u/',
 'hi , i have a special', ', i have a special offer',
 'i have a special offer available', 'have a special offer available for',
 'a special offer available for you', 'special offer available for you at',
 'offer available for you at our', 'available for you at our casino',
 'for you at our casino .', 'you at our casino . \$', 'at our casino . \$ 20',
 'our casino . \$ 20 to', 'casino . \$ 20 to try', '. \$ 20 to try our',
 '\$ 20 to try our internet', '20 to try our internet casino',
 'to try our internet casino ,', 'try our internet casino , no',
 'our internet casino , no deposit', 'internet casino , no deposit is',
 'casino , no deposit is necessary', ', no deposit is necessary !',
 'no deposit is necessary ! at', 'deposit is necessary ! at the',
 'is necessary ! at the casino', 'necessary ! at the casino software',
 '! at the casino software 's', 'at the casino software 's cashier",
 "the casino software 's cashier enter",
 "casino software 's cashier enter bonus",
 "software 's cashier enter bonus code", "'s cashier enter bonus code :",
 'cashier enter bonus code : fr93p', 'enter bonus code : fr93p \$',
 'bonus code : fr93p \$ 200', 'code : fr93p \$ 200 bonus',
 ': fr93p \$ 200 bonus on', 'fr93p \$ 200 bonus on your',
 '\$ 200 bonus on your first', '200 bonus on your first deposit',
 'bonus on your first deposit !', 'on your first deposit ! at',
 'your first deposit ! at the', 'first deposit ! at the casino',
 'deposit ! at the casino software', "! at the casino software 's",
 "at the casino software 's cashier", "the casino software 's cashier enter",
 "casino software 's cashier enter bonus",
 "software 's cashier enter bonus code", "'s cashier enter bonus code :",
 'cashier enter bonus code : fmjku', 'enter bonus code : fmjku allow',
 'bonus code : fmjku allow us', 'code : fmjku allow us to',
 ': fmjku allow us to show', 'fmjku allow us to show you',
 'allow us to show you our', 'us to show you our quality',
 'to show you our quality operation', 'show you our quality operation ,',
 'you our quality operation , fast', 'our quality operation , fast payouts',
 'quality operation , fast payouts ,', 'operation , fast payouts , generous',
 ', fast payouts , generous bonuses', 'fast payouts , generous bonuses ,',
 'payouts , generous bonuses , and', ', generous bonuses , and super',
 'generous bonuses , and super friendly',
 'bonuses , and super friendly around-the-clock',
 ', and super friendly around-the-clock customer',
 'and super friendly around-the-clock customer support',
 'super friendly around-the-clock customer support .',

'friendly around-the-clock customer support . click',
 'around-the-clock customer support . click here',
 'customer support . click here :', 'support . click here : http',
 '. click here : http :', 'click here : http : //bigbonus-casino.net',
 'here : http : //bigbonus-casino.net best',
 ': http : //bigbonus-casino.net best regards',
 'http : //bigbonus-casino.net best regards ,',
 ': //bigbonus-casino.net best regards , jamie',
 '//bigbonus-casino.net best regards , jamie zawinsky',
 'best regards , jamie zawinsky no', 'regards , jamie zawinsky no thanks',
 ', jamie zawinsky no thanks :', 'jamie zawinsky no thanks : http',
 'zawinsky no thanks : http :', 'no thanks : http : //bigbonus-casino.com/u/',
 'hi , i have a special offer', ', i have a special offer available',
 'i have a special offer available for',
 'have a special offer available for you',
 'a special offer available for you at',
 'special offer available for you at our',
 'offer available for you at our casino', 'available for you at our casino .',
 'for you at our casino . \$', 'you at our casino . \$ 20',
 'at our casino . \$ 20 to', 'our casino . \$ 20 to try',
 'casino . \$ 20 to try our', '. \$ 20 to try our internet',
 '\$ 20 to try our internet casino', '20 to try our internet casino ,',
 'to try our internet casino , no', 'try our internet casino , no deposit',
 'our internet casino , no deposit is',
 'internet casino , no deposit is necessary',
 'casino , no deposit is necessary !', ', no deposit is necessary ! at',
 'no deposit is necessary ! at the', 'deposit is necessary ! at the casino',
 'is necessary ! at the casino software',
 'necessary ! at the casino software 's', '! at the casino software 's cashier',
 'at the casino software 's cashier enter',
 'the casino software 's cashier enter bonus',
 'casino software 's cashier enter bonus code',
 'software 's cashier enter bonus code :',
 "'s cashier enter bonus code : fr93p", 'cashier enter bonus code : fr93p \$',
 'enter bonus code : fr93p \$ 200', 'bonus code : fr93p \$ 200 bonus',
 'code : fr93p \$ 200 bonus on', ': fr93p \$ 200 bonus on your',
 'fr93p \$ 200 bonus on your first', '\$ 200 bonus on your first deposit',
 '200 bonus on your first deposit !', 'bonus on your first deposit ! at',
 'on your first deposit ! at the', 'your first deposit ! at the casino',
 'first deposit ! at the casino software',
 'deposit ! at the casino software 's', '! at the casino software 's cashier',
 'at the casino software 's cashier enter',
 'the casino software 's cashier enter bonus',
 'casino software 's cashier enter bonus code',
 'software 's cashier enter bonus code :',
 "'s cashier enter bonus code : fmjku",
 'cashier enter bonus code : fmjku allow', 'enter bonus code : fmjku allow us',
 'bonus code : fmjku allow us to', 'code : fmjku allow us to show',

': fmjku allow us to show you', 'fmjku allow us to show you our',
 'allow us to show you our quality', 'us to show you our quality operation',
 'to show you our quality operation ,', 'show you our quality operation , fast',
 'you our quality operation , fast payouts',
 'our quality operation , fast payouts ,',
 'quality operation , fast payouts , generous',
 'operation , fast payouts , generous bonuses',
 ', fast payouts , generous bonuses ,', 'fast payouts , generous bonuses , and',
 'payouts , generous bonuses , and super',
 ', generous bonuses , and super friendly',
 'generous bonuses , and super friendly around-the-clock',
 'bonuses , and super friendly around-the-clock customer',
 ', and super friendly around-the-clock customer support',
 'and super friendly around-the-clock customer support .',
 'super friendly around-the-clock customer support . click',
 'friendly around-the-clock customer support . click here',
 'around-the-clock customer support . click here :',
 'customer support . click here : http', 'support . click here : http :',
 '. click here : http : //bigbonus-casino.net',
 'click here : http : //bigbonus-casino.net best',
 'here : http : //bigbonus-casino.net best regards',
 ': http : //bigbonus-casino.net best regards ,',
 'http : //bigbonus-casino.net best regards , jamie',
 ': //bigbonus-casino.net best regards , jamie zawinsky',
 '//bigbonus-casino.net best regards , jamie zawinsky no',
 'best regards , jamie zawinsky no thanks',
 'regards , jamie zawinsky no thanks :', ', jamie zawinsky no thanks : http',
 'jamie zawinsky no thanks : http :',
 'zawinsky no thanks : http : //bigbonus-casino.com/u/',
 'hi , i have a special offer available',
 ', i have a special offer available for',
 'i have a special offer available for you',
 'have a special offer available for you at',
 'a special offer available for you at our',
 'special offer available for you at our casino',
 'offer available for you at our casino .',
 'available for you at our casino . \$', 'for you at our casino . \$ 20',
 'you at our casino . \$ 20 to', 'at our casino . \$ 20 to try',
 'our casino . \$ 20 to try our', 'casino . \$ 20 to try our internet',
 '. \$ 20 to try our internet casino', '\$ 20 to try our internet casino ,',
 '20 to try our internet casino , no',
 'to try our internet casino , no deposit',
 'try our internet casino , no deposit is',
 'our internet casino , no deposit is necessary',
 'internet casino , no deposit is necessary !',
 'casino , no deposit is necessary ! at', ', no deposit is necessary ! at the',
 'no deposit is necessary ! at the casino',
 'deposit is necessary ! at the casino software',

"is necessary ! at the casino software 's",
 "necessary ! at the casino software 's cashier",
 "! at the casino software 's cashier enter",
 "at the casino software 's cashier enter bonus",
 "the casino software 's cashier enter bonus code",
 "casino software 's cashier enter bonus code :",
 "software 's cashier enter bonus code : fr93p",
 "'s cashier enter bonus code : fr93p \$",
 'cashier enter bonus code : fr93p \$ 200',
 'enter bonus code : fr93p \$ 200 bonus', 'bonus code : fr93p \$ 200 bonus on',
 'code : fr93p \$ 200 bonus on your', ': fr93p \$ 200 bonus on your first',
 'fr93p \$ 200 bonus on your first deposit',
 '\$ 200 bonus on your first deposit !', '200 bonus on your first deposit ! at',
 'bonus on your first deposit ! at the',
 'on your first deposit ! at the casino',
 'your first deposit ! at the casino software',
 "first deposit ! at the casino software 's",
 "deposit ! at the casino software 's cashier",
 "! at the casino software 's cashier enter",
 "at the casino software 's cashier enter bonus",
 "the casino software 's cashier enter bonus code",
 "casino software 's cashier enter bonus code :",
 "software 's cashier enter bonus code : fmjku",
 "'s cashier enter bonus code : fmjku allow",
 'cashier enter bonus code : fmjku allow us',
 'enter bonus code : fmjku allow us to', 'bonus code : fmjku allow us to show',
 'code : fmjku allow us to show you', ': fmjku allow us to show you our',
 'fmjku allow us to show you our quality',
 'allow us to show you our quality operation',
 'us to show you our quality operation ,',
 'to show you our quality operation , fast',
 'show you our quality operation , fast payouts',
 'you our quality operation , fast payouts ,',
 'our quality operation , fast payouts , generous',
 'quality operation , fast payouts , generous bonuses',
 'operation , fast payouts , generous bonuses ,',
 ', fast payouts , generous bonuses , and',
 'fast payouts , generous bonuses , and super',
 'payouts , generous bonuses , and super friendly',
 ', generous bonuses , and super friendly around-the-clock',
 'generous bonuses , and super friendly around-the-clock customer',
 'bonuses , and super friendly around-the-clock customer support',
 ', and super friendly around-the-clock customer support .',
 'and super friendly around-the-clock customer support . click',
 'super friendly around-the-clock customer support . click here',
 'friendly around-the-clock customer support . click here :',
 'around-the-clock customer support . click here : http',
 'customer support . click here : http :',

'support . click here : http : //bigbonus-casino.net',
 '. click here : http : //bigbonus-casino.net best',
 'click here : http : //bigbonus-casino.net best regards',
 'here : http : //bigbonus-casino.net best regards ,',
 ': http : //bigbonus-casino.net best regards , jamie',
 'http : //bigbonus-casino.net best regards , jamie zawinsky',
 ': //bigbonus-casino.net best regards , jamie zawinsky no',
 '//bigbonus-casino.net best regards , jamie zawinsky no thanks',
 'best regards , jamie zawinsky no thanks :',
 'regards , jamie zawinsky no thanks : http',
 ', jamie zawinsky no thanks : http :',
 'jamie zawinsky no thanks : http : //bigbonus-casino.com/u/',
 'hi , i have a special offer available for',
 ', i have a special offer available for you',
 'i have a special offer available for you at',
 'have a special offer available for you at our',
 'a special offer available for you at our casino',
 'special offer available for you at our casino .',
 'offer available for you at our casino . \$',
 'available for you at our casino . \$ 20', 'for you at our casino . \$ 20 to',
 'you at our casino . \$ 20 to try', 'at our casino . \$ 20 to try our',
 'our casino . \$ 20 to try our internet',
 'casino . \$ 20 to try our internet casino',
 '. \$ 20 to try our internet casino ,', '\$ 20 to try our internet casino , no',
 '20 to try our internet casino , no deposit',
 'to try our internet casino , no deposit is',
 'try our internet casino , no deposit is necessary',
 'our internet casino , no deposit is necessary !',
 'internet casino , no deposit is necessary ! at',
 'casino , no deposit is necessary ! at the',
 ', no deposit is necessary ! at the casino',
 'no deposit is necessary ! at the casino software',
 'deposit is necessary ! at the casino software 's',
 'is necessary ! at the casino software 's cashier',
 'necessary ! at the casino software 's cashier enter',
 '! at the casino software 's cashier enter bonus',
 'at the casino software 's cashier enter bonus code',
 'the casino software 's cashier enter bonus code :',
 'casino software 's cashier enter bonus code : fr93p',
 'software 's cashier enter bonus code : fr93p \$',
 "'s cashier enter bonus code : fr93p \$ 200",
 'cashier enter bonus code : fr93p \$ 200 bonus',
 'enter bonus code : fr93p \$ 200 bonus on',
 'bonus code : fr93p \$ 200 bonus on your',
 'code : fr93p \$ 200 bonus on your first',
 ': fr93p \$ 200 bonus on your first deposit',
 'fr93p \$ 200 bonus on your first deposit !',
 '\$ 200 bonus on your first deposit ! at',

'200 bonus on your first deposit ! at the',
 'bonus on your first deposit ! at the casino',
 'on your first deposit ! at the casino software',
 "your first deposit ! at the casino software 's",
 "first deposit ! at the casino software 's cashier",
 "deposit ! at the casino software 's cashier enter",
 "! at the casino software 's cashier enter bonus",
 "at the casino software 's cashier enter bonus code",
 "the casino software 's cashier enter bonus code :",
 "casino software 's cashier enter bonus code : fmjku",
 "software 's cashier enter bonus code : fmjku allow",
 "'s cashier enter bonus code : fmjku allow us",
 'cashier enter bonus code : fmjku allow us to',
 'enter bonus code : fmjku allow us to show',
 'bonus code : fmjku allow us to show you',
 'code : fmjku allow us to show you our',
 ': fmjku allow us to show you our quality',
 'fmjku allow us to show you our quality operation',
 'allow us to show you our quality operation ,',
 'us to show you our quality operation , fast',
 'to show you our quality operation , fast payouts',
 'show you our quality operation , fast payouts ,',
 'you our quality operation , fast payouts , generous',
 'our quality operation , fast payouts , generous bonuses',
 'quality operation , fast payouts , generous bonuses ,',
 'operation , fast payouts , generous bonuses , and',
 ', fast payouts , generous bonuses , and super',
 'fast payouts , generous bonuses , and super friendly',
 'payouts , generous bonuses , and super friendly around-the-clock',
 ', generous bonuses , and super friendly around-the-clock customer',
 'generous bonuses , and super friendly around-the-clock customer support',
 'bonuses , and super friendly around-the-clock customer support .',
 ', and super friendly around-the-clock customer support . click',
 'and super friendly around-the-clock customer support . click here',
 'super friendly around-the-clock customer support . click here :',
 'friendly around-the-clock customer support . click here : http',
 'around-the-clock customer support . click here : http :',
 'customer support . click here : http : //bigbonus-casino.net',
 'support . click here : http : //bigbonus-casino.net best',
 '. click here : http : //bigbonus-casino.net best regards',
 'click here : http : //bigbonus-casino.net best regards ,',
 'here : http : //bigbonus-casino.net best regards , jamie',
 ': http : //bigbonus-casino.net best regards , jamie zawinsky',
 'http : //bigbonus-casino.net best regards , jamie zawinsky no',
 ': //bigbonus-casino.net best regards , jamie zawinsky no thanks',
 '//bigbonus-casino.net best regards , jamie zawinsky no thanks :',
 'best regards , jamie zawinsky no thanks : http',
 'regards , jamie zawinsky no thanks : http :',

```
[48]: vectorizador.fit_transform([contenido_mensaje_5]).toarray()[0]
```

```
[49]: from pathlib import Path
```

```

    try:
        mensaje = analizador_mensaje.parse(fichero_mensaje)
        contenidos_mensajes_entrenamiento.append(mensaje.get_content())
        clases_mensajes_entrenamiento.append(0)
    except (KeyError, UnicodeDecodeError, LookupError):
        pass

# Leemos los mensajes no deseados (clase 1)
for ruta_mensaje in (carpeta_entrenamiento / 'no_deseado').iterdir():
    with open(ruta_mensaje, 'r') as fichero_mensaje:
        try:
            mensaje = analizador_mensaje.parse(fichero_mensaje)
            contenidos_mensajes_entrenamiento.append(mensaje.get_content())
            clases_mensajes_entrenamiento.append(1)
        except (KeyError, UnicodeDecodeError, LookupError):
            pass

```

```

[52]: bolsa_de_palabras_entrenamiento = vectorizador.transform(
        contenidos_mensajes_entrenamiento
    )
bolsa_de_palabras_entrenamiento

```

```

[52]: <Compressed Sparse Row sparse matrix of dtype 'int64'
      with 84608 stored elements and shape (20991, 494)>

```

Ahora haremos una búsqueda en rejilla para determinar el mejor valor de suavizado para el modelo naive Bayes multinomial. Como nuestro objetivo es identificar los mensajes no deseados, elegimos la sensibilidad como medida de rendimiento.

```

[53]: from sklearn.naive_bayes import MultinomialNB
      from sklearn.model_selection import GridSearchCV

```

```

[26]: filtro_NB = MultinomialNB()
      búsqueda_en_rejilla = GridSearchCV(
          filtro_NB,
          {'alpha': range(1, 5)},
          scoring='recall',
          cv=5
      )
      búsqueda_en_rejilla.fit(bolsa_de_palabras_entrenamiento,
                              clases_mensajes_entrenamiento)

```

```

[26]: GridSearchCV(cv=5, estimator=MultinomialNB(), param_grid={'alpha': range(1, 5)},
                  scoring='recall')

```

```

[27]: búsqueda_en_rejilla.best_params_

```

```

[27]: {'alpha': 1}

```

```
[28]: búsqueda_en_rejilla.best_score_
```

```
[28]: np.float64(0.616353887399464)
```

Para construir un filtro de correo electrónico no deseado usando el modelo tf-idf como modelo de lenguaje y el modelo k NN como modelo predictivo, basta replicar convenientemente los pasos realizados anteriormente.

```
[54]: from sklearn.feature_extraction.text import TfidfVectorizer
```

```
[56]: vectorizador = TfidfVectorizer(vocabulary=términos_spam,
                                     token_pattern=None,
                                     tokenizer=word_tokenize,
                                     ngram_range=(1, 9))

# Calculamos la frecuencia documental inversa a partir de todos los
# mensajes de entrenamiento
vectorizador.fit(contenidos_mensajes_entrenamiento)

# Construimos la representación tf-idf del mensaje no deseado 5
vectorizador.transform([contenido_mensaje_5]).toarray()
```

[illegible]

21

[illegible]

Sin embargo, en este caso existe la dificultad de que la frecuencia documental inversa debe calcularse únicamente a partir del corpus de entrenamiento. Esto quiere decir que la búsqueda en rejilla debe realizar tanto la vectorización de los mensajes como la construcción del modelo predictivo.

Es necesario, entonces, el uso de las tuberías de scikit-learn. Además, por eficiencia, se usará la clase `TfidfTransformer` para obtener directamente las frecuencias documentales inversas a partir de la bolsa de palabras ya construida.

```
[57]: from sklearn.pipeline import Pipeline
      from sklearn.feature_extraction.text import TfidfTransformer
      from sklearn.neighbors import KNeighborsClassifier
```

```
[58]: tubería_filtro_kNN = Pipeline([
        ('vectorizador', TfidfTransformer()),
        ('filtro_kNN', KNeighborsClassifier(metric='cosine'))
    ])
```

```
[59]: búsqueda_en_rejilla = GridSearchCV(
    tubería_filtro_kNN,
    {'filtro_kNN_n_neighbors': range(1, 6, 2)},
    scoring='recall',
    cv=5
)
```

```
búsqueda_en_rejilla.fit(bolsa_de_palabras_entrenamiento,
                        clases_mensajes_entrenamiento)
```

```
[59]: GridSearchCV(cv=5,
                  estimator=Pipeline(steps=[('vectorizador', TfidfTransformer()),
                                           ('filtro_kNN',
                                            KNeighborsClassifier(metric='cosine'))]),
                  param_grid={'filtro_kNN_n_neighbors': range(1, 6, 2)},
                  scoring='recall')
```

```
[60]: búsqueda_en_rejilla.best_params_
```

```
[60]: {'filtro_kNN_n_neighbors': 1}
```

```
[61]: búsqueda_en_rejilla.best_score_
```

```
[61]: np.float64(0.8348759221998658)
```

La conclusión es, por tanto, que de todos los filtros considerados, el que mejor identifica los mensajes no deseados es el modelo *k*NN con el valor 1 para el número de vecinos.

Procedemos a entrenar ese modelo sobre todo el corpus de entrenamiento y a evaluar su rendimiento sobre el corpus de prueba.

```
[62]: filtro_seleccionado = Pipeline([
      ('vectorizador', TfidfVectorizer(vocabulary=términos_spam,
                                      token_pattern=None,
                                      tokenizer=word_tokenize,
                                      ngram_range=(1, 9))),
      ('filtro_kNN', KNeighborsClassifier(metric='cosine',
                                         n_neighbors=1))
    ])
```

```
[63]: filtro_seleccionado.fit(contenidos_mensajes_entrenamiento,
                              clases_mensajes_entrenamiento)
```

```
[63]: Pipeline(steps=[('vectorizador',
                      TfidfVectorizer(ngram_range=(1, 9), token_pattern=None,
                      tokenizer=<function word_tokenize at
                      0x7125d85798a0>,
                      vocabulary=['#1', '$$$', '$earn extra cash',
                      '$save big money', '$save',
                      '100% free', '100% satisfied',
                      '100%', '4u', '50% off',
                      'accept credit cards',
                      'acceptance', 'access',
                      'accordingly', 'act now!',
                      'act now', 'action', 'ad',
                      'additional income', 'additional',
```

```

        'addresses on cd', 'affordable',
        'all natural', 'all new', 'amazed',
        'amazing stuff', 'amazing',
        'americans', 'apply now',
        'apply online', ...]],
        ('filtro_kNN',
         KNeighborsClassifier(metric='cosine', n_neighbors=1)))]

```

```

[64]: carpeta_prueba = carpeta_Enron_Spam / 'test'

contenidos_mensajes_prueba = []
clases_mensajes_prueba = []

# Leemos los mensajes legítimos (clase 0)
for ruta_mensaje in (carpeta_prueba / 'legítimo').iterdir():
    with open(ruta_mensaje, 'r') as fichero_mensaje:
        try:
            mensaje = analizador_mensaje.parse(fichero_mensaje)
            contenidos_mensajes_prueba.append(mensaje.get_content())
            clases_mensajes_prueba.append(0)
        except (KeyError, UnicodeDecodeError, LookupError):
            pass

# Leemos los mensajes no deseados (clase 1)
for ruta_mensaje in (carpeta_prueba / 'no_deseado').iterdir():
    with open(ruta_mensaje, 'r') as fichero_mensaje:
        try:
            mensaje = analizador_mensaje.parse(fichero_mensaje)
            contenidos_mensajes_prueba.append(mensaje.get_content())
            clases_mensajes_prueba.append(1)
        except (KeyError, UnicodeDecodeError, LookupError):
            pass

```

```

[65]: from sklearn.metrics import recall_score

```

```

[66]: predicciones_mensajes_prueba = filtro_seleccionado.predict(
        contenidos_mensajes_prueba)
recall_score(clases_mensajes_prueba, predicciones_mensajes_prueba)

```

```

[66]: 0.8380849919311458

```

4.2 Sistema de texto predictivo

Los sistemas de texto predictivo son una tecnología de entrada de texto diseñada para dispositivos móviles. Esta tecnología permite formar palabras presionando una zona de la pantalla asociada a un grupo de letras. La aplicación principal de esta tecnología es simplificar la escritura de mensajes de texto.

Aunque esta tecnología se utilizó inicialmente para facilitar la escritura de mensajes en teléfonos móviles con teclado numérico, la aparición del smartphone con teclado ampliado provocó que cambiase el tipo de aplicaciones a las que se aplica. Actualmente se utiliza tanto para facilitar la escritura en teclados ampliados (samsung swype) como para sugerir nuevas entradas de texto (escritura inteligente). También es notable su uso en dispositivos móviles más pequeños como los Smart Watch.

Los sistemas de texto predicen la palabra que queremos escribir a partir de las pulsaciones realizadas. Para ello han efectuado previamente un análisis estadístico de un corpus de textos de referencia, determinando las probabilidades de las correspondencias entre distintas secuencias de pulsaciones y posibles palabras.

Estos sistemas suelen mostrar la palabra que corresponde con mayor probabilidad a la combinación de pulsaciones realizada por el usuario, actualizándose esta palabra a medida que el usuario realiza nuevas pulsaciones. Además, es habitual ofrecer al usuario la posibilidad de requerir otras posibilidades, aparte de aceptar la palabra propuesta por el sistema.

La efectividad de un sistema de predicción de texto dependerá de varios factores:

- La calidad del corpus.
- El modelo de lenguaje obtenido a partir del análisis estadístico del corpus.

En esta segunda parte de la práctica se va utilizar la biblioteca NLTK para construir un sistema de predicción de texto en español basado en modelos de n -gramas.

En primer lugar se debe cargar un corpus de textos en español que nos permita entrenar el modelo. Por ejemplo, el [corpus InfoLibros](#) es un corpus de 218 millones de tókenes de narrativas españolas extraídas de libros gratuitos recopilados por el proyecto abierto [Infolibros.org](#). Por motivos de eficiencia computacional, nosotros usaremos únicamente una parte de ese corpus, guardado en el fichero `Texto predictivo/corpus_InfoLibros_parcial.txt`.

NLTK proporciona diferentes clases que permiten leer corpus de muy diversos tipos. Entre ellas se encuentra la clase `PlaintextCorpusReader` para leer corpus proporcionados en ficheros de texto plano, como es el caso que nos ocupa. Para identificar las frases contenidas en el corpus, usaremos el modelo proporcionado por NLTK para el español, creando para ello una instancia adecuada de la clase `PunktTokenizer`. Mantendremos la separación por defecto de cada una de esas frases en palabras que sean secuencias solo de caracteres alfanuméricos o solo de caracteres no alfanuméricos, aunque ese comportamiento también es configurable.

```
[67]: # Nos aseguramos de haber descargado el tokenizador
```

```
from nltk import download

download('punkt_tab')
```

```
[nltk_data] Downloading package punkt_tab to ...
```

```
[nltk_data] Package punkt_tab is already up-to-date!
```

```
[67]: True
```

```
[68]: from nltk.corpus.reader.plaintext import PlaintextCorpusReader
      from nltk.tokenize.punkt import PunktTokenizer
```

```
[69]: corpus_InfoLibros = PlaintextCorpusReader(
    root='Texto predictivo',
    fileids=['corpus_InfoLibros_parcial.txt'],
    encoding='utf8',
    sent_tokenizer=PunktTokenizer(lang='spanish')
)
```

Los métodos `paras`, `sents` y `words` proporcionan, respectivamente, los párrafos, frases y palabras identificados en el corpus.

```
[70]: for para in corpus_InfoLibros.paras()[:5]:
    pprint(para[:3] + [['...']], compact=True)
    print()
```

```
[['Venga', 'usted', 'aquí', ',', 'querida', 'Elena', '-', 'dijo', 'Ana',
  'Pavlovna', 'a', 'la', 'bella', 'Princesa', ',', 'que', ',', 'sentada', 'un',
  'poco', 'más', 'lejos', ',', 'formaba', 'el', 'centro', 'del', 'otro',
  'grupo', '.'],
 ['La', 'princesa', 'Elena', 'sonrió', 'y', 'se', 'levantó', 'con', 'la',
  'misma', 'invariable', 'sonrisa', 'de', 'mujer', 'absolutamente', 'hermosa',
  'con', 'que', 'había', 'entrado', 'en', 'el', 'salón', '.'],
 ['Con', 'el', 'ligero', 'rumor', 'de', 'su', 'leve', 'vestido', 'de', 'baile',
  'con', 'adornos', 'de', 'felpa', ',', 'deslumbradora', 'por', 'la',
  'blancura', 'de', 'sus', 'hombros', 'y', 'el', 'esplendor', 'de', 'sus',
  'cabellos', 'y', 'de', 'sus', 'diamantes', ',', 'cruzó', 'entre', 'los',
  'hombres', ',', 'que', 'le', 'abrieron', 'paso', ',', 'rígida', ',', 'sin',
  'ver', 'a', 'nadie', ',', 'pero', 'sonriendo', 'a', 'todos', 'como', 'si',
  'concediese', 'a', 'cada', 'uno', 'el', 'derecho', 'de', 'admirar', 'la',
  'belleza', 'de', 'su', 'aspecto', ',', 'de', 'sus', 'redondeados', 'hombros',
  ',', 'de', 'su', 'espalda', ',', 'de', 'su', 'pecho', ',', 'muy', 'escotado',
  ',', 'según', 'la', 'moda', 'de', 'la', 'época', ',', 'y', 'con', 'su',
  'gracioso', 'caminar', 'se', 'acercó', 'a', 'Ana', 'Pavlovna', '.'],
 ['...']]
```

```
[['Libro', 'descargado', 'en', 'www', '.', 'elejandria', '.', 'com', ',', 'tu',
  'sitio', 'web', 'de', 'obras', 'de', 'dominio', 'público', '|', 'Esperamos',
  'que', 'lo', 'disfrutéis', '!'],
 ['Las', 'Aventuras', 'de', 'Pinocho', 'Por', 'C', '.', 'Collodi', 'I', 'Cómo',
  'fue', 'que', 'el', 'maestro', 'Cereza', ',', 'carpintero', 'de', 'oficio',
  ',', 'encontró', 'un', 'palo', 'que', 'lloraba', 'y', 'reía', 'como', 'un',
  'niño', '.'],
 ['-¡', 'Un', 'rey', '!'], ['...']]
```

```
[['La', 'Comunicación', 'no', 'verbal', '(', 'CNV', ')', 'y', 'su', 'relación',
  'con', 'la', 'interpretación', 'es', 'el', 'tema', 'que', 'pretendemos',
  'abordar', 'en', 'este', 'trabajo', '.'],
 ['Muchos', 'estudiosos', 'consideran', 'importante', 'conocer', 'este', 'tipo',
  'de', 'comunicación', ',', 'para', 'una', 'mejor', 'compresión', 'del',
```

```

'mensaje', ',', 'una', 'reproducción', 'más', 'fidedigna', 'del', 'mismo',
',', 'por', 'ende', 'un', 'mejor', 'trabajo', 'del', 'intérprete', '.'],
['Se', 'realiza', 'un', 'análisis', 'de', 'la', 'CNV', ',', 'de', 'forma',
'específica', 'la', 'kinesica', 'y', 'la', 'paralingüística', '.'],
['...']]

[['Este', 'documento', 'no', 'ha', 'sido', 'sometido', 'a', 'revision',
'editorial', '.'],
['Este', 'documento', 'contiene', 'el', 'material', 'docente', 'empleado',
'por', 'el', 'Banco', 'Interamericano', 'de', 'Desarrollo', '(', 'BID', ')',
'y', 'el', 'Instituto', 'Latinoamericano', 'de', 'Planificación', 'Económica',
'y', 'Social', '(', 'ILPES', ')', 'en', 'el', 'marco', 'del', 'programa',
'de', 'Capacitación', 'para', 'los', 'países', 'C', 'y', 'DI', '.'],
['El', 'proposito', 'de', 'este', 'programa', 'es', 'contribuir', 'al',
'desarrollo', 'de', 'una', 'capacidad', 'nacional', 'permanente', 'de',
'entrenamiento', 'a', 'funcionarios', 'de', 'las', 'instituciones',
'responsables', 'de', 'la', 'gestión', 'de', 'programas', 'y', 'proyectos',
'.'],
['...']]

[['A', 'mi', 'madre', 'con', 'infinito', 'cariño', '.'],
['A', 'mi', 'padre', 'dondequiera', 'que', 'se', 'encuentre', '.'],
['A', 'mi', 'hijo', 'Eliud', 'que', 'es', 'el', 'motivo', 'de', 'mi',
'existencia', '.'],
['...']]

```

```
[71]: pprint(corpus_InfoLibros.sents()[:5], compact=True)
```

```

['Venga', 'usted', 'aquí', ',', 'querida', 'Elena', '-', 'dijo', 'Ana',
'Pavlovna', 'a', 'la', 'bella', 'Princesa', ',', 'que', ',', 'sentada', 'un',
'poco', 'más', 'lejos', ',', 'formaba', 'el', 'centro', 'del', 'otro',
'grupo', '.'],
['La', 'princesa', 'Elena', 'sonrió', 'y', 'se', 'levantó', 'con', 'la',
'misma', 'invariable', 'sonrisa', 'de', 'mujer', 'absolutamente', 'hermosa',
'con', 'que', 'había', 'entrado', 'en', 'el', 'salón', '.'],
['Con', 'el', 'ligero', 'rumor', 'de', 'su', 'leve', 'vestido', 'de', 'baile',
'con', 'adornos', 'de', 'felpa', ',', 'deslumbradora', 'por', 'la',
'blancura', 'de', 'sus', 'hombros', 'y', 'el', 'esplendor', 'de', 'sus',
'cabellos', 'y', 'de', 'sus', 'diamantes', ',', 'cruzó', 'entre', 'los',
'hombres', ',', 'que', 'le', 'abrieron', 'paso', ',', 'rígida', ',', 'sin',
'ver', 'a', 'nadie', ',', 'pero', 'sonriendo', 'a', 'todos', 'como', 'si',
'concediese', 'a', 'cada', 'uno', 'el', 'derecho', 'de', 'admirar', 'la',
'belleza', 'de', 'su', 'aspecto', ',', 'de', 'sus', 'redondeados', 'hombros',
',', 'de', 'su', 'espalda', ',', 'de', 'su', 'pecho', ',', 'muy', 'escotado',
',', 'según', 'la', 'moda', 'de', 'la', 'época', ',', 'y', 'con', 'su',
'gracioso', 'caminar', 'se', 'acercó', 'a', 'Ana', 'Pavlovna', '.'],
['Elena', 'era', 'tan', 'hermosa', 'que', 'no', 'solamente', 'no', 'veíase',

```

```
'en', 'ella', 'una', 'sombra', 'de', 'coquetería', ',', 'sino', 'que', ',',
'al', 'contrario', ',', 'parecía', 'que', 'se', 'avergonzase', 'de', 'su',
'indiscutible', 'belleza', ',', 'que', 'ejercía', 'victoriosamente', 'sobre',
'los', 'demás', 'una', 'influencia', 'demasiado', 'fuerte', '.'],
['Hubiérase', 'dicho', 'que', 'deseaba', ',', 'sin', 'poder', 'conseguirlo',
',', 'amenguar', 'el', 'efecto', 'de', 'su', 'hermosura', '.']]
```

```
[72]: pprint(corpus_InfoLibros.words()[:50], compact=True)
```

```
['Venga', 'usted', 'aquí', ',', 'querida', 'Elena', '-', 'dijo', 'Ana',
'Pavlovna', 'a', 'la', 'bella', 'Princesa', ',', 'que', ',', 'sentada', 'un',
'poco', 'más', 'lejos', ',', 'formaba', 'el', 'centro', 'del', 'otro', 'grupo',
',', 'La', 'princesa', 'Elena', 'sonrió', 'y', 'se', 'levantó', 'con', 'la',
'misma', 'invariable', 'sonrisa', 'de', 'mujer', 'absolutamente', 'hermosa',
'con', 'que', 'había', 'entrado']
```

Siguiendo el procedimiento habitual en aprendizaje automático, dividimos el corpus en un subcorpus de entrenamiento y un subcorpus de prueba. Sin embargo, debido al tamaño del corpus, una división aleatoria resulta muy costosa computacionalmente. Es por ello que para el corpus de entrenamiento seleccionaremos el 80 % de las frases iniciales del corpus, dejando para el corpus de prueba el 20 % de las frases finales.

```
[73]: total_frases = len(corpus_InfoLibros.sents())
total_frases
```

```
[73]: 1008664
```

```
[74]: total_frases_entrenamiento = int(total_frases * .8)
total_frases_entrenamiento
```

```
[74]: 806931
```

```
[75]: corpus_entrenamiento = corpus_InfoLibros.sents()[:total_frases_entrenamiento]
corpus_prueba = corpus_InfoLibros.sents()[total_frases_entrenamiento:]
```

El primer paso en la construcción del sistema de texto predictivo consiste en identificar el vocabulario de todas las palabras que aparecen en el corpus de entrenamiento. Para ello se hará uso de la clase `Vocabulary`, que proporciona una estructura de tipo diccionario que guarda el número de ocurrencias de cada palabra identificada. Esto permite establecer un número mínimo de ocurrencias para que una palabra se considere parte del vocabulario.

```
[76]: from nltk.lm.vocabulary import Vocabulary
# flatten es una utilidad que permite aplanar listas de listas
from nltk.lm.preprocessing import flatten
```

```
[77]: vocabulario_palabras = Vocabulary(
    flatten(corpus_entrenamiento), # lista de todas las palabras
    unk_cutoff=50 # mínimo número de ocurrencias
)
```

El vocabulario incluye por defecto el término <UNK> para representar los términos desconocidos que no aparecen en el corpus de entrenamiento.

```
[78]: # Hola aparece en el corpus de entrenamiento y, por tanto,  
# pertenece al vocabulario  
vocabulario_palabras.lookup('Hola')
```

```
[78]: 'Hola'
```

```
[79]: # hola no aparece en el corpus de entrenamiento y, por tanto,  
# es un término desconocido  
vocabulario_palabras.lookup('hola')
```

```
[79]: '<UNK>'
```

Por otra parte, los símbolos especiales de inicio y fin de secuencia que es necesario considerar en los modelos de n -gramas hay que incluirlos explícitamente en el vocabulario y, además, en este caso con frecuencia 50, para que sean considerados parte del vocabulario.

```
[80]: inicio_frase = '<s>'  
fin_frase = '</s>'  
vocabulario_palabras.update({inicio_frase: 50, fin_frase: 50})
```

La siguiente función facilitará delimitar adecuadamente, en función de los n -gramas pretendidos, las frases con esos símbolos especiales.

```
[81]: def delimita_frase(frase, n):  
    return ['<s>'] * (n - 1) + frase + ['</s>']
```

```
[82]: primera_frase_entrenamiento = corpus_entrenamiento[0]  
pprint(delimita_frase(primera_frase_entrenamiento, 1),  
       compact=True)  
pprint(delimita_frase(primera_frase_entrenamiento, 2),  
       compact=True)  
pprint(delimita_frase(primera_frase_entrenamiento, 3),  
       compact=True)
```

```
['Venga', 'usted', 'aquí', ',', 'querida', 'Elena', '-', 'dijo', 'Ana',  
'Pavlovna', 'a', 'la', 'bella', 'Princesa', ',', 'que', ',', 'sentada', 'un',  
'poco', 'más', 'lejos', ',', 'formaba', 'el', 'centro', 'del', 'otro', 'grupo',  
'.', '</s>']
```

```
['<s>', 'Venga', 'usted', 'aquí', ',', 'querida', 'Elena', '-', 'dijo', 'Ana',  
'Pavlovna', 'a', 'la', 'bella', 'Princesa', ',', 'que', ',', 'sentada', 'un',  
'poco', 'más', 'lejos', ',', 'formaba', 'el', 'centro', 'del', 'otro', 'grupo',  
'.', '</s>']
```

```
['<s>', '<s>', 'Venga', 'usted', 'aquí', ',', 'querida', 'Elena', '-', 'dijo',  
'Ana', 'Pavlovna', 'a', 'la', 'bella', 'Princesa', ',', 'que', ',', 'sentada',  
'un', 'poco', 'más', 'lejos', ',', 'formaba', 'el', 'centro', 'del', 'otro',  
'grupo', '.', '</s>']
```

Para obtener los n -gramas de una frase basta aplicar la función `ngrams` de NLTK, o específicamente las funciones `bigrams` y `trigrams` para los bigramas y trigramas.

```
[83]: from nltk.util import ngrams, bigrams, trigrams
```

```
[84]: list(ngrams(delimita_frase(primer_frase_entrenamiento, 1), n=1))
```

```
[84]: [('Venga',),  
      ('usted',),  
      ('aquí',),  
      ('',),  
      ('querida',),  
      ('Elena',),  
      ('-',),  
      ('dijo',),  
      ('Ana',),  
      ('Pavlovna',),  
      ('a',),  
      ('la',),  
      ('bella',),  
      ('Princesa',),  
      ('',),  
      ('que',),  
      ('',),  
      ('sentada',),  
      ('un',),  
      ('poco',),  
      ('más',),  
      ('lejos',),  
      ('',),  
      ('formaba',),  
      ('el',),  
      ('centro',),  
      ('del',),  
      ('otro',),  
      ('grupo',),  
      ('.',),  
      ('</s>',)]
```

```
[85]: list(bigrams(delimita_frase(primer_frase_entrenamiento, 2)))
```

```
[85]: [('<s>', 'Venga'),  
      ('Venga', 'usted'),  
      ('usted', 'aquí'),  
      ('aquí', ''),  
      ('', 'querida'),  
      ('querida', 'Elena'),  
      ('Elena', '-'),
```

```
( '-', 'dijo'),
('dijo', 'Ana'),
('Ana', 'Pavlovna'),
('Pavlovna', 'a'),
('a', 'la'),
('la', 'bella'),
('bella', 'Princesa'),
('Princesa', ', '),
(', ', 'que'),
('que', ', '),
(', ', 'sentada'),
('sentada', 'un'),
('un', 'poco'),
('poco', 'más'),
('más', 'lejos'),
('lejos', ', '),
(', ', 'formaba'),
('formaba', 'el'),
('el', 'centro'),
('centro', 'del'),
('del', 'otro'),
('otro', 'grupo'),
('grupo', '. '),
('. ', '</s>'))]
```

```
[86]: list(trigrams(delimita_frase(primer_frase_entrenamiento, 3)))
```

```
[86]: [('<s>', '<s>', 'Venga'),
        ('<s>', 'Venga', 'usted'),
        ('Venga', 'usted', 'aquí'),
        ('usted', 'aquí', ', '),
        ('aquí', ', ', 'querida'),
       (', ', 'querida', 'Elena'),
        ('querida', 'Elena', '-'),
        ('Elena', '-', 'dijo'),
        ('-', 'dijo', 'Ana'),
        ('dijo', 'Ana', 'Pavlovna'),
        ('Ana', 'Pavlovna', 'a'),
        ('Pavlovna', 'a', 'la'),
        ('a', 'la', 'bella'),
        ('la', 'bella', 'Princesa'),
        ('bella', 'Princesa', ', '),
        ('Princesa', ', ', 'que'),
       (', ', 'que', ', '),
        ('que', ', ', 'sentada'),
       (', ', 'sentada', 'un'),
        ('sentada', 'un', 'poco'),
```

```
( 'un', 'poco', 'más'),
( 'poco', 'más', 'lejos'),
( 'más', 'lejos', ','),
( 'lejos', ', ', 'formaba'),
( ', ', 'formaba', 'el'),
( 'formaba', 'el', 'centro'),
( 'el', 'centro', 'del'),
( 'centro', 'del', 'otro'),
( 'del', 'otro', 'grupo'),
( 'otro', 'grupo', '.'),
( 'grupo', '.', '</s>')]
```

La clase `MLE` implementa los modelos de n -gramas de máxima verosimilitud y la clase `Laplace` los modelos análogos que, adicionalmente, incorporan un suavizado de Laplace. Para crear instancias de esas clases hay que proporcionar el orden de los n -gramas y el vocabulario de términos. Una vez creadas, se entrenan aplicando el método `fit` a la secuencia de las secuencias de n -gramas de cada frase de entrenamiento y se evalúa aplicando el método `perplexity` a la secuencia de los n -gramas de todas las frases de prueba.

```
[87]: from nltk.lm import MLE, Laplace
```

```
[88]: modelo_unigrama_MLE = MLE(1, vocabulary=vocabulario_palabras)
      modelo_unigrama_MLE.fit(ngrams(delimita_frase(frase, 1), n=1)
                             for frase in corpus_entrenamiento)
      modelo_unigrama_MLE.perplexity(flatten(ngrams(delimita_frase(frase, 1), n=1)
                                                for frase in corpus_prueba))
```

```
[88]: 569.4380946356334
```

```
[89]: modelo_unigrama_Laplace = Laplace(1, vocabulary=vocabulario_palabras)
      modelo_unigrama_Laplace.fit(ngrams(delimita_frase(frase, 1), n=1)
                                  for frase in corpus_entrenamiento)
      modelo_unigrama_Laplace.perplexity(flatten(ngrams(delimita_frase(frase, 1), n=1)
                                                      for frase in corpus_prueba))
```

```
[89]: 569.4578979334117
```

```
[90]: modelo_bigrama_MLE = MLE(2, vocabulary=vocabulario_palabras)
      modelo_bigrama_MLE.fit(bigrams(delimita_frase(frase, 2))
                             for frase in corpus_entrenamiento)
      modelo_bigrama_MLE.perplexity(flatten(bigrams(delimita_frase(frase, 2))
                                                for frase in corpus_prueba))
```

```
[90]: inf
```

La perplejidad no tiene una cota superior absoluta. Se calcula como el inverso de la probabilidad asignada por el modelo al corpus de prueba, normalizado por la cantidad de términos que este contiene.

- Puesto que el modelo puede asignar a una secuencia una probabilidad arbitrariamente pequeña (muy cercana a 0), el valor inverso puede crecer indefinidamente hacia el infinito
- De hecho, si el modelo se encuentra con una secuencia a la que le asigna una probabilidad de 0 (por ejemplo, si no se han aplicado técnicas de suavizado ante palabras desconocidas), la perplejidad se dispararía matemáticamente al **infinito**.

Se interpreta siguiendo esta regla principal: En cuanto a su interpretación, la perplejidad evalúa el nivel de “sorpresa” o “duda” de un modelo de lenguaje al enfrentarse a un texto real nuevo.

- Cuanto menor sea el valor de la perplejidad, mejor será el modelo. Un valor bajo (cuyo límite inferior ideal roza el 1) significa que el modelo ha asignado una probabilidad alta a la secuencia real, es decir, el texto encaja perfectamente con lo que el modelo esperaba leer.
- Una perplejidad muy alta indica que el modelo está sumamente “sorprendido” por la secuencia, ya que la considera altamente improbable basándose en lo que aprendió en su entrenamiento. Como vimos en los ejercicios anteriores, si una frase está compuesta puramente por elementos “raros” o poco frecuentes, la duda del modelo se dispara y la perplejidad alcanza valores máximos correspondientes a la inversa de esa probabilidad mínima.

```
[91]: modelo_bigrama_Laplace = Laplace(2, vocabulary=vocabulario_palabras)
      modelo_bigrama_Laplace.fit(bigrams(delimita_frase(frase, 2))
                                for frase in corpus_entrenamiento)
      modelo_bigrama_Laplace.perplexity(flatten(bigrams(delimita_frase(frase, 2))
                                                for frase in corpus_prueba))
```

[91]: 366.2692890116132

```
[66]: modelo_trigrama_MLE = MLE(3, vocabulary=vocabulario_palabras)
      modelo_trigrama_MLE.fit(trigrams(delimita_frase(frase, 3))
                              for frase in corpus_entrenamiento)
      modelo_trigrama_MLE.perplexity(flatten(trigrams(delimita_frase(frase, 3))
                                              for frase in corpus_prueba))
```

[66]: inf

```
[67]: modelo_trigrama_Laplace = Laplace(3, vocabulary=vocabulario_palabras)
      modelo_trigrama_Laplace.fit(trigrams(delimita_frase(frase, 3))
                                  for frase in corpus_entrenamiento)
      modelo_trigrama_Laplace.perplexity(flatten(trigrams(delimita_frase(frase, 3))
                                                  for frase in corpus_prueba))
```

[67]: 2138.444556966786

El mejor modelo parece ser, por tanto, el modelo bigrama con suavizado de Laplace, ya que es el que *menos perplejo se queda* ante el corpus de prueba.

La idea es, entonces, usar estos modelos para predecir, a partir de las palabras anteriores y de las letras de la palabra ya escritas, qué palabra se pretende escribir.

```
[92]: def predice_palabras(prefijo, contexto, numero_palabras, modelo):
      def puntua_palabra(palabra):
          return modelo.score(palabra, contexto) # contexto debe ser una tupla
      palabras_candidatas = filter(lambda palabra: palabra.startswith(prefijo),
                                   vocabulario_palabras)
      palabras_candidatas_ordenadas = sorted(palabras_candidatas,
                                              key=puntua_palabra,
                                              reverse=True)
      return palabras_candidatas_ordenadas[:numero_palabras]
```

Por ejemplo, si se ha escrito *Procesamiento del lenguaje nat* podríamos usar el modelo bigrama con suavizado de Laplace (luego el contexto sería una tupla con la palabra *lenguaje*) para predecir las cinco palabras más probables que se estarían queriendo escribir.

```
[93]: predice_palabras('nat', ('lenguaje',), 5, modelo_bigrama_Laplace)
```

```
[93]: ['natural', 'naturalmente', 'nata', 'naturales', 'naturaleza']
```